

## Derin Öğrenme Tabanlı Otomatik Beyin Tümör Tespiti

Bu makalede en yaygın ölüm türü olan beyin tümörü üzerinde alınan MRG görüntüleri üzerine MobilNetV2 derin öğrenme modeli ile birlikte k en yakın komşu (k-EYK) algoritması ile beyin tümörü tespit edilmesi üzerine çalışılmıştır

Beyin tümörü hayatı tehdit eden ölümcül bir hastalıktır bu hastalığın erken teşhisi tedavi için çok önemlidir.

MRG yöntemi yöntemi de beynin yumuşak dokusu hakkında yüksek çözünürlüklü bilginin yanı sıra aynı dokuya ait birden fazla şekilsel bilgi de sağlamaktadır. Bu nedenle, beyin cerrahları beyindeki en küçük anormallikleri tespit için onlara yeterli bilgi sağladığında yaygın olarak kullanılmaktadırlar.

Literatürde beyin tümörü teşhisine yönelik makine öğrenmesi ve derin öğrenme modelleri yaygın olarak kullanılmıştır. Yapılan örnek çalışmalar:

Arı ve diğerleri MR görüntülerini bölütleterek sınıflandırma yapmış ve **%83,39 doğruluk** elde etmişlerdir.

Bulut ve diğerleri segmentasyona dayalı Markov Rastgele Alan yöntemini kullanarak **%87 doğruluk** oranına ulaşmışlardır.

Mohsen ve diğerleri Derin Öğrenme ve Ayrık Dalgacık Dönüşümü (ADD) temelli yeni bir yöntem önererek **%93,94 doğruluk** oranını yakalamışlardır.

Afşar ve diğerleri CapsNet temelli yöntemleri ile MR görüntülerinden elde ettikleri 64 öznitelik ile sınıflandırma yaparak **%86,56 doğruluk** elde etmişlerdir.

Vani ve diğerleri Destek Vektör Makinesi (DVM) temelli yöntemleriyle beyin tümörünü pozitif-negatif sınıflarında sırasıyla **%82 ve %81,48 doğruluk** ile tahmin etmişlerdir.

Çıtak ve diğerleri DVM, Çok Katmanlı Algılayıcılar (ÇKA) ve Lojistik Regresyon (LR) olmak üzere üç farklı model kullanarak **%93 doğruluk** oranına ulaşmışlardır.

Shahzadi ve diğerleri AlexNet ve VGGNet gibi transfer öğrenimi modellerini Uzun Kısa Süreli Bellek (UKSB) ile birleştirmiş ve sırasıyla **%71 (AlexNet)** ve **%84 (VGGNet)** doğruluk elde etmişlerdir.

Bu çalışmada beyin tümörlerini tespiti için önceden eğitilmiş ESA modellerinden MobileNetV2 ve k-en yakın komşu (k-EYK) temelli bir model önerilmiştir. Bu modelde öznitelik çıkarımı için MobileNetV2 kullanılmıştır. MobileNetV2 modeli mobil cihazlara veya düşük hesaplama gücüne sahip herhangi bir cihazda kullanılabildiği için tercih edilmiştir. Derin öznitelikler sınıflandırılma performansının artırılması için k-EYK sınıflandırıcıya uygulanmıştır. Çalışmanın literatüre katkıları şunlardır;

- Daha düşük kapasiteli donanımlarda kullanılabilecek bir ESA modeli önerildi

- MobileNetV2 genelleme performansının artırılması için veri çoğaltma yapıldı.
- k-EYK sınıflandırıcı ile sınıflandırma performansları arttırıldı.

Bu çalışmada beyin tümörünün varlığını iki sınıf (tümörlü ve tümörsüz) olarak belirlemek amacıyla derin öğrenme tabanlı bir model geliştirilmiştir. Önerilen yöntem üç temel adımdan oluşmaktadır:

### 1. Veri Çoğaltma ve Ön İşleme:

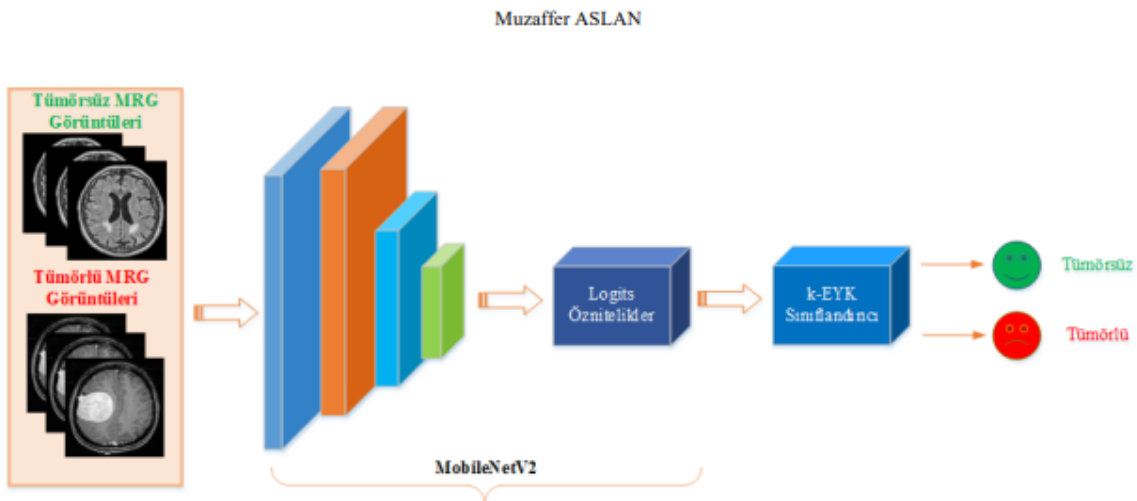
- Başlangıçta kullanılan **253 MR görüntüsü**, veri çoğaltma teknikleriyle **1265 görüntüye** çıkarılmıştır.
- Görüntüler, MobileNetV2 modeli giriş boyutuna göre **224×224×3** boyutuna getirilmiştir.

### 2. Derin Öznitelik Çıkarımı:

- Görüntülere önceden eğitilmiş **MobileNetV2** modeli uygulanmıştır.
- Modelin “**Logits**” tam bağlı katmanından **1000 derin öznitelik** elde edilmiştir.

### 3. Sınıflandırma:


- Elde edilen derin öznitelikler, **k-En Yakın Komşu (k-EYK)** sınıflandırıcısı kullanılarak tümör varlığı açısından sınıflandırılmıştır.
- Modelin başarımını en üst düzeye çıkarmak için sınıflandırıcı parametreleri deneysel yöntemlerle optimize edilmiştir.



Şekil 1. Önerilen modelin blok diyagramı

## Veri seti ve veri çoğaltma

Veri seti 155'i tümörlü ve 98'i tümörsüz olmak üzere iki sınıflı toplam 253 MRG görüntüsünden oluşmaktadır. Veri seti uzmanlar tarafından gönüllü hastalardan elde edilmiştir. Görüntülerin her biri JPEG biçimini ve çeşitli çözünürlüklere sahiptirler.



Şekil 2. Veri setinde sınıflara ait görüntüler

Derin öğrenme modellerinin başarısı için **veri kümesinin büyüklüğü** kritik öneme sahiptir. Bu çalışmada veri sayısını artırmak için aşağıdaki çoğaltma yöntemleri kullanılmıştır:


**Yatay çevirme, Dikey çevirme, Yatay-Dikey eksenlerde çevirme, 90° döndürme, 270° döndürme**

Başlangıçta **253 MR görüntüsü** bulunan veri seti, bu yöntemlerle **775'i tümörlü, 490'ı tümörsüz** olmak üzere toplam **1265 görüntüye** çıkarılmıştır.

Bu veri çoğaltma adımlarıyla derin öğrenme modelinin performansı artırılarak:

- **Genelleme yeteneği geliştirilmiş**
- **Aşırı öğrenme (overfitting) azaltılmıştır.**

Derin Öğrenme Tabanlı Otomatik Beyin Tümör Tespiti



Şekil 3. Veri çoğaltma yöntemlerine ait örnek görüntüler

## Evriřimli sinir ađı

Evriřimli Sinir Ađları (ESA), grnt iřleme ve sınıflandırmada yaygın olarak kullanılan, ok katmanlı derin đrenme modelleridir. ESA'lar genel olarak řu  temel katmandan oluřmaktadır:

### 1. Evriřim Katmanı (*Convolution Layer*)

- Grntlerden zellik ıkarma iřlemini gerekleřtirir.
- Filtreler (3x3, 5x5, vb.) grnt zerinde kaydırılarak, grntnn zelliklerini ortaya ıkarır.

### 2. Havuzlama Katmanı (*Pooling Layer*)

- Grntdeki bilgileri basitleřtirmek ve boyut azaltmak iin kullanılır.
- Bylece hesaplama yk azalır, nemli zellikler korunur ve grltye karřı diren artar.

### 3. Tam Bađlantılı Katman (*Fully Connected Layer*)

- Bu katmanda, nceki katmanlardan elde edilen zellikler dzleřtirilir (matris → vektr).
- Elde edilen derin zellikler sınıflandırılır ve sonuca dnřtrlr.

## Transfer đrenimi nedir?

Transfer đrenimi, yeni farklı verileri đrenmek iin nceden eđitilmiř modeli kullanarak diđer sorunları zmek iin nceden đrenilmiř zelliklerin kullanmasıdır.

Bu alıřmada, 1000 sınıfı tahmin etmek iin 1,28 milyon grnt (ImageNet) kullanılarak eđitilmiř MobileNetV2 ESA modeli kullanılmıřtır.

## MobilNetV2

MobileNetV2, Google tarafından 2017 yılında nerilen ve mobil cihazlar gibi dřk kapasiteli cihazlar iin optimize edilmiř, hafif bir Derin Evriřimli Sinir Ađı (ESA) modelidir.

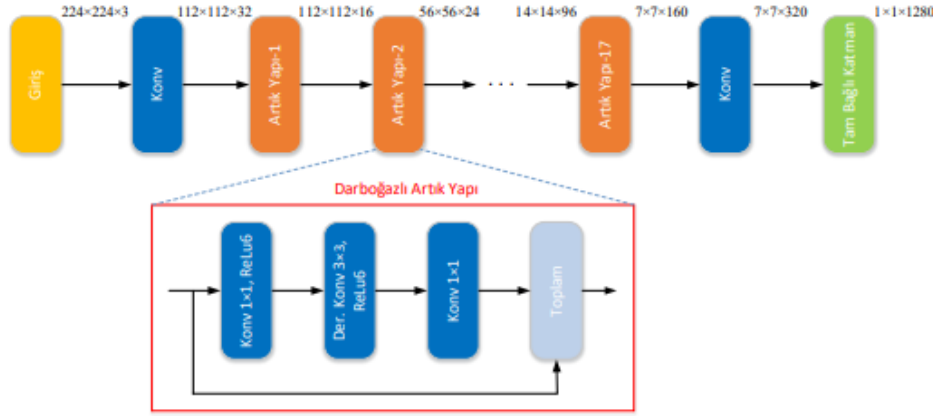
Temel zellikleri:

- MobileNetV1'in geliřmiř bir srmdr.
- Derinlemesine Ayarlanabilen Evriřimleri temel alır ve bylece model boyutunu ve iřlem maliyetini nemli lde azaltır.
- Darbođaz Katmanı (bottleneck layer) olarak adlandırılan zel katman yapısına sahiptir.

Darbođaz Katmanı Yapısı:

- 1x1 evriřim (sıkıřtırma): Özelliklerin sayısını azaltır.
- 3x3 derinlemesine evriřim: Özellik çıkarımı yapar.
- 1x1 evriřim (geniřletme): Özellikleri tekrar artırarak daha zengin temsil sağlar.
- Bu katmanlarda kullanılan aktivasyon fonksiyonu ReLU6'dır.

MobileNetV2, bu tasarım sayesinde model boyutunu küçültürken doğruluk ve eğitim hızını arttırmaktadır.



Şekil 4. MobileNetV2 modelinin yapısı

## k-EYK sınıflandırıcı

K-en yakın komşu, denetimli öğrenme temelli bir örüntü sınıflandırma algoritmasıdır. K-EYK, komşularının çoğunluk oyu ile görüntüleri sınıflandırır. Uzaklık matrisini oluşturmak için test görüntüsü öznitelikleri ile her eğitim bir görüntüsü öznitelikleri arasındaki uzaklık mesafesi kullanılır. Uzaklık matrisinin toplam değeri tahmin edilir ve daha sonra artan şekilde sıralanır. İlk olarak k eleman seçilir. Son olarak görüntüyü sınıflandırmak için çoğunluk sınıfının değeri belirlenir. Uzaklık hesaplamasında çoğunlukla Öklid , Minkowski ve Manhattan.

## Performans değerlendirme kriterleri

**Doğruluk (Accuracy)**  $(TP + TN) / (TP + FP + TN + FN)$  Modelin genel doğruluğu.

**Duyarlılık (Recall)**  $TP / (TP + FN)$  Tümörlü görüntüleri doğru tespit oranı.

**Özgüllük (Specificity)**  $TN / (TN + FP)$  Sağlıklı görüntüleri doğru tespit oranı.

**Keskinlik (Precision)**  $TP / (TP + FP)$  Pozitif tahminlerin doğru çıkma oranı.

**F1 Skoru** Precision ve Recall'ın harmonik ortalaması Dengeli performans ölçütü.

<b>Matthews Korelasyon Katsayısı (MCC)</b>	-1 ile +1 arasında	Dengesiz veri setlerinde güvenilir performans ölçütü.
--	--------------------	---

#### Deneysel Çalışma Ortamı:

- **MobilNetV2** modeli **MATLAB Derin Öğrenme Araç Kutusu** ile kullanıldı.
- Deneyler; %80 eğitim (1012 görüntü), %20 test (253 görüntü) olacak şekilde gerçekleştirildi.
- Kullanılan bilgisayar: **NVIDIA GPU destekli , 403 hafıza, 16 GB RAM**

#### Model Eğitimi ve Test Süreci:

- Eğitim sürecinde **SGDM ve ADAM** optimizasyon algoritmaları test edildi.
- En iyi sonuçlar, **k-En Yakın Komşu (k-EYK)** sınıflandırıcısıyla elde edildi (**k=5**).
- 5 kat çapraz doğrulama yöntemi kullanılarak doğruluk sağlandı.

#### Performans Sonuçları:

- Başlangıçtaki (253 görüntülük) orijinal veri seti kullanılarak elde edilen doğruluk sınırlıydı:
  - MobileNetV2 ve k-EYK ile sınıflandırma doğruluğu sırasıyla daha düşük çıktı.
- Veri çoğaltma ile görüntü sayısı 1265'e çıkarıldı ve modelin performansı önemli ölçüde arttı:

Model	Doğruluk	Duyarlılık	Özgüllük	Keskinlik	F1 Skor	MCC
<b>MobileNetV2+k-EYK</b>	<b>%96,44</b>	%96,94	%96,13	%94,06	%95,48	0,925

- Veri çoğaltma yöntemleri sonrası k-EYK ile doğruluk oranında **%6,72**, MCC değerinde **%7,5** artış sağlandı.

#### Diğer Yöntemlerle Karşılaştırma:

- Literatürdeki diğer yöntemlerle karşılaştırıldığında önerilen model (**MobileNetV2+k-EYK**), benzer ESA modelleri olan **VGG19 (%94,82)** ve **ResNet50 (%95)**'den daha yüksek (**%96,44**) doğruluğa ulaşmıştır.

#### Eğitim Süresi ve Optimizasyon:

- Önerilen yöntem, transfer öğrenme yaklaşımı sayesinde hızlı ve etkin eğitilmiş, parametre optimizasyonu sonucunda öğrenme süreci başarıyla tamamlanmıştır.

**Sonu ve Gelecek alıřmalar:**

- nerilen yntem uzmanlara karar desteęi saęlamayı amalamaktadır.
- Gelecek alıřmalarda daha byk ve eřitli veri kmeleriyle farklı trlerdeki beyin tmrlerinin sınıflandırılması hedeflenmektedir.